INFORME TÉCNICO V1.0.0-OFFLINE

DATE A LIVE AI: APLICACIÓN DESKTOP OFFLINE & RPG LOCAL

Sistema interactivo de escritorio con IA conversacional local (Ollama / llama3.2:3b) y batallas por turnos.

01. RESUMEN EJECUTIVO

Independencia de la Nube y Privacidad Absoluta

Privacidad y Costo Nulo

Sin envío de datos a servidores externos. Elimina latencia de red y costos por suscripción API.

Entretenimiento Híbrido

Combina chats conversacionales fluidos con un subsistema de batallas por turnos estilo RPG local.

02. INFRAESTRUCTURA

Arquitectura en 3 Capas



Frontend Web

HTML / JS Liviano
(127.0.0.1:8765)



Backend FastAPI

main.py / db.py
(SQLite Persistente)



Ollama Engine

llama3.2:3b
(Puerto 11434)

03. ESTRUCTURA MODULAR

Componentes Clave del Sistema

desktop/launcher.py: Inicia Uvicorn/FastAPI y abre la interfaz automáticamente en el navegador.

backend/main.py: Define endpoints REST para chats, acciones de combate y recursos multimedia.

backend/ai.py: Comunicación asíncrona con Ollama para respuestas estructuradas por personaje.

backend/db.py: Base de datos SQLite para almacenamiento de historial, partidas y equipos.

04. ESPÍRITUS PRINCIPALES

Elencos e Interacciones RPG

Kotori Itsuka

Ángel: Camael

Liderazgo táctico y ataque elemental de fuego en modo RPG.

Kurumi Tokisaki

Ángel: Zaphkiel

Lógica conversacional avanzada y alto daño por manipulación temporal.

Miku Izayoi

Ángel: Gabriel

Especialista en soporte, melodías y potenciación de equipo.

Mukuro Hoshimiya

Ángel: Michael

Control de batalla, bloqueo y alteración de estados enemigos.

05. VERIFICACIÓN TÉCNICA

Pruebas Funcionales y Diagnóstico

Prueba	Procedimiento	Resultado	Estado
Creación de Chat	POST /api/chats	HTTP 200 OK - Registrado en SQLite	COMPROBADO
Inferencia IA Local	POST /api/chat/message	HTTP 200 OK - Respuesta vía Ollama	COMPROBADO
Acción RPG Combate	POST /api/battle/action	HTTP 200 OK - Turno procesado	COMPROBADO
Síntesis de Voz (TTS)	GET /api/tts	HTTP 404 Not Found (Falta módulo)	PENDIENTE

06. HOJA DE RUTA

Módulo Piper TTS y Optimizaciones

Diagnóstico Error 404 TTS

Integración técnica parcialmente implementada. Requiere la descarga e inclusión local de los binarios del modelo de voz de Piper.

Mejoras Futuras

Optimización del consumo de VRAM en GPUs de gama media e integración de modelos cuantizados de mayor eficiencia.

CONCLUSIÓN DEL PROYECTO

Viabilidad Comprobada de SLMs Locales

El sistema demuestra que es totalmente factible ejecutar aplicaciones multimedia interactivas y complejas sin depender de APIs de pago ni conexión a Internet.